Analisis Eksplorasi Data
Seattle Cycle Share (trip.csv)

Mata Kuliah Analisis Big Data - Bab 1: Statistics and Probability

Dosen: Prof. Dr. Ir. Amil Ahmad Ilham, S.T., M.IT

Dokumen ini menjelaskan **analisis data** dari output tiap listing, bukan kodenya. Bagian **2a** membahas output Listing 1-1 s.d. 1-14 (notebook 2a). Bagian **2b** membahas distribusi jumlah trip per tahun, bulan, hari, dan harian, ditambah analisis multivariat (notebook 2b). Seluruh angka berasal dari *trip.csv*: 236.065 trip, 13 Oktober 2014 s.d. 31 Agustus 2016.

2a. Analisis Output Listing 1-1 s.d. 1-14

Listing 1-1 s.d. 1-3: Pemuatan data dan gambaran awal

Listing 1-1 dan 1-2 tidak menghasilkan output (impor paket dan pembacaan file). Listing 1-3 menunjukkan dataset berisi **236.065 trip** dengan 12 kolom. Lima trip pertama terjadi pada 13 Oktober 2014 pukul 10:31-10:34, semuanya berdurasi sekitar 15 menit, dilakukan *Member*, dan memiliki data gender serta tahun lahir.

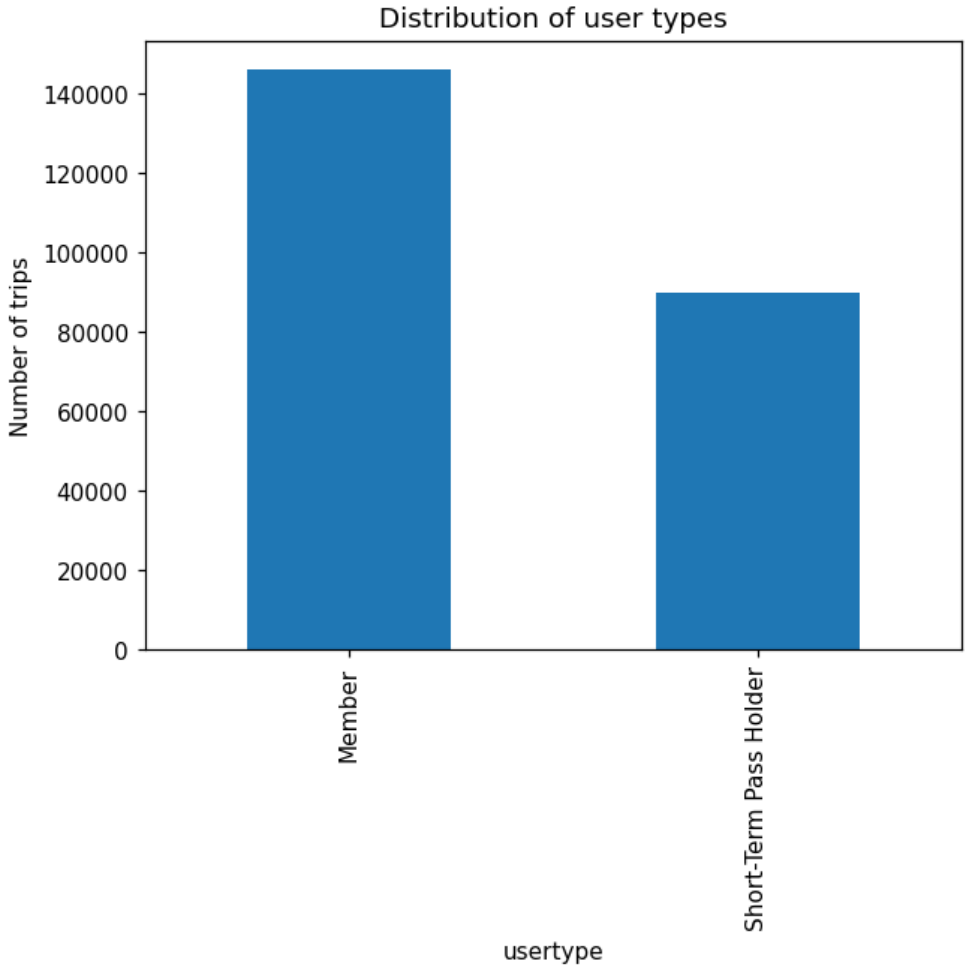
Pemeriksaan nilai kosong menunjukkan hanya dua kolom yang tidak lengkap: *gender* kosong pada **89.894** baris dan *birthyear* pada **89.898** baris (sekitar 38% data). Kolom lain lengkap. Kekosongan ini bukan acak, dan alasannya terlihat pada Listing 1-11 dan 1-12.

Listing 1-4: Rentang waktu dataset

Data mencakup **13/10/2014 10:31** sampai **01/09/2016 00:20**, yaitu 689 hari (23 bulan kalender). Setiap tanggal dalam rentang itu memiliki minimal satu trip, jadi tidak ada hari yang hilang.

Catatan: buku menampilkan awal rentang 10/13/2014 10:32 karena kodenya mengambil baris kedua dari data yang diurutkan sebagai teks. Waktu mulai paling awal yang sebenarnya adalah 10:31, sehingga listing ini memakai nilai minimum dari kolom datetime.

Listing 1-5: Distribusi tipe pengguna

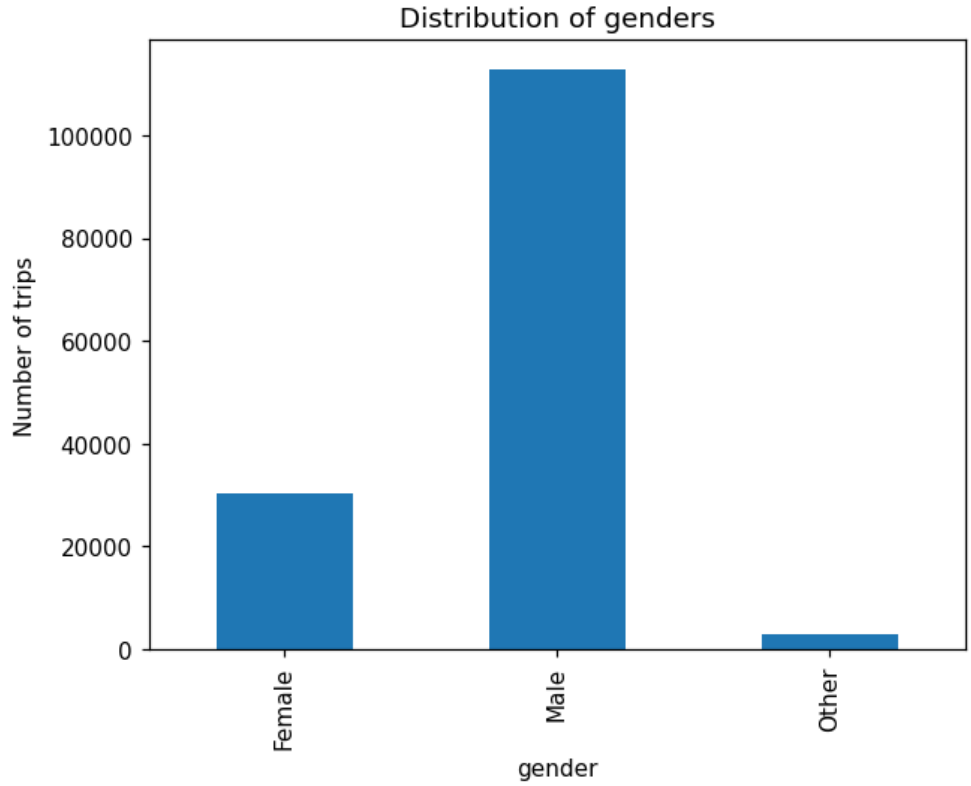


Gambar: jumlah trip per tipe pengguna.

Member melakukan **146.171 trip (61,9%)**, sedangkan *Short-Term Pass Holder* **89.894 trip (38,1%)**; rasionya sekitar 1,6 banding 1. Ini mendukung pandangan bahwa anggota berlangganan menyumbang trip lebih banyak daripada pemakai jangka pendek.

Dua tipe ini juga berbeda perilakunya. Rata-rata durasi Member 593 detik (median 479), sedangkan Short-Term 2.194 detik (median 1.251). Trip lebih dari satu jam hanya 0,4% pada Member tetapi 14,6% pada Short-Term. Pola ini konsisten dengan Member sebagai pemakai rutin dan Short-Term sebagai pemakai rekreasi atau wisata (ini interpretasi, bukan fakta yang tercatat dalam data).

Listing 1-6: Distribusi gender

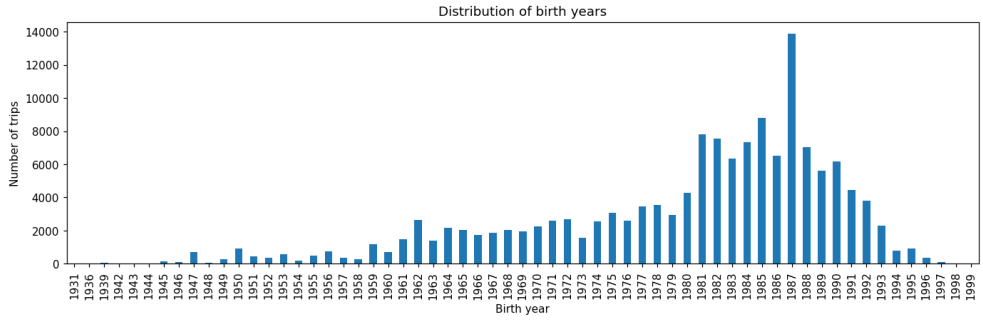


Gambar: jumlah trip per gender.

Laki-laki **112.940 (77,3%)**, perempuan **30.330 (20,7%)**, dan *Other* **2.901 (2,0%)**, dihitung dari 146.171 trip yang gendernya tercatat. Pengguna laki-laki sekitar 3,7 kali pengguna perempuan.

Grafik ini tidak memuat 89.894 trip tanpa gender, sehingga angka tersebut bukan gambaran seluruh pengguna melainkan hanya anggota berlangganan (dibuktikan di Listing 1-12). Selain itu, yang dihitung adalah trip, bukan orang: satu pengguna yang sering bersepeda dihitung berkali-kali.

Listing 1-7: Distribusi tahun lahir

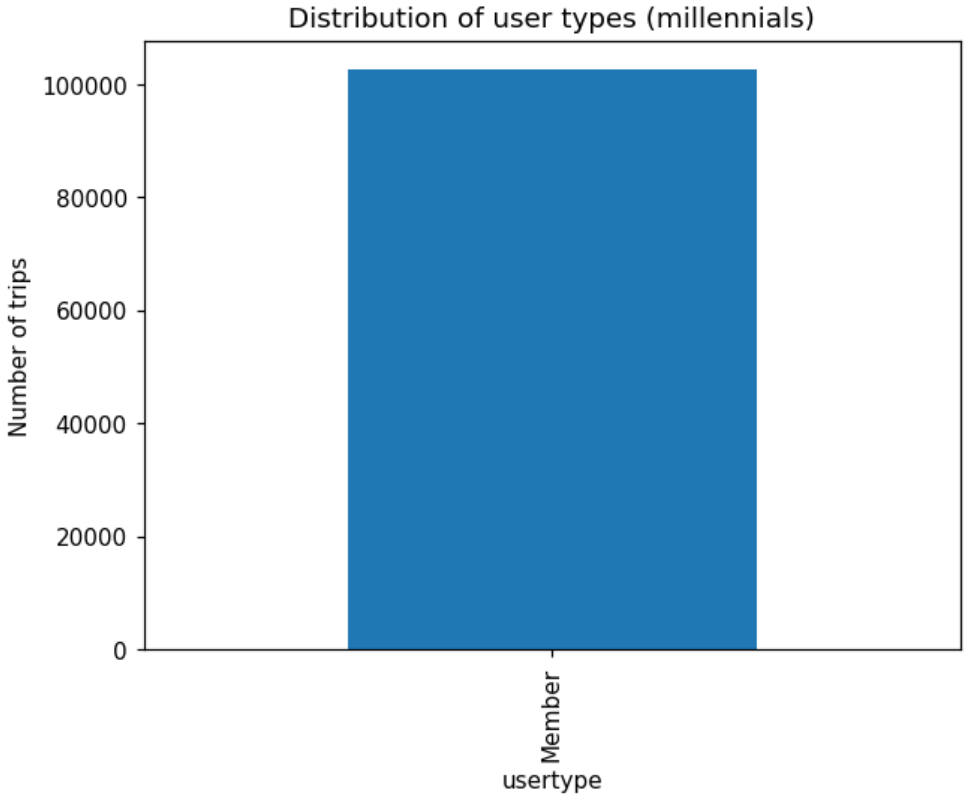


Gambar: jumlah trip per tahun lahir.

Tahun lahir tercatat untuk 146,167 trip, berkisar **1931-1999** dengan median **1983** dan rata-rata 1979,9. Modus jatuh pada **1987** (13.904 trip), disusul 1985 (8.793) dan 1981 (7.797). Pada masa data (2014-2016) kelompok ini berusia sekitar 27-35 tahun.

Bentuknya condong ke kiri: ekor panjang ke tahun lahir yang lebih tua, dan hanya 204 trip (0,14%) berasal dari pengguna kelahiran 1945 atau lebih awal. Pengguna terbanyak adalah orang dewasa usia produktif.

Listing 1-8: Tipe pengguna pada kelompok milenial (lahir 1977-1994)

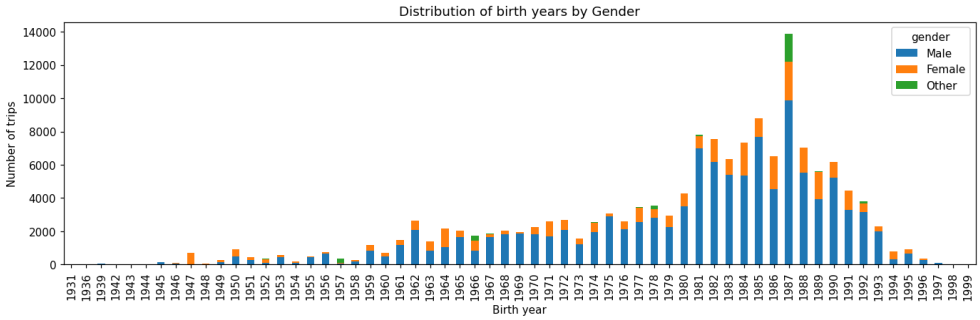


Gambar: jumlah trip milenial per tipe pengguna.

Kelompok milenial menghasilkan **102.677 trip**, atau 70,2% dari trip yang memiliki tahun lahir. Seluruhnya **100% Member**; tidak ada satu pun Short-Term Pass Holder.

Sekilas ini tampak seperti loyalitas milenial yang sangat tinggi. Namun Listing 1-11 menunjukkan bahwa tahun lahir memang tidak pernah tercatat untuk Short-Term Pass Holder, sehingga kesimpulan loyalitas ini tidak sah. Hasil ini adalah artefak pencatatan data.

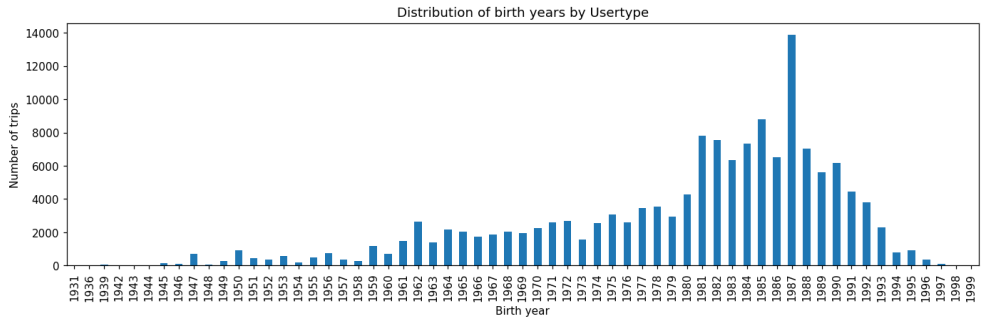
Listing 1-9: Tahun lahir menurut gender



Gambar: jumlah trip per tahun lahir, ditumpuk menurut gender.

Puncak laki-laki dan perempuan sama-sama pada tahun lahir **1987** (9.889 trip laki-laki, 2.333 trip perempuan). Bentuk sebaran kedua gender hampir serupa; perbedaannya terutama pada skala, dengan laki-laki lebih banyak pada 53 dari 61 tahun lahir (perempuan unggul hanya pada 8 tahun lahir di ujung usia tua dan muda, yang jumlahnya sangat kecil). Kategori *Other* (2.901 trip) terlalu kecil untuk terlihat pada grafik.

Listing 1-10: Tahun lahir menurut tipe pengguna



Gambar: jumlah trip Member per tahun lahir.

Grafik ini hanya menampilkan *Member* dan bentuknya hampir identik dengan Listing 1-7. Alasannya, hampir semua trip yang memiliki tahun lahir berasal dari Member (146.167 dari 146.171 trip Member). Hanya 4 trip Member yang tahun lahirnya kosong. Karena Short-Term Pass Holder tidak punya tahun lahir, perbandingan antartipe pengguna menurut umur tidak bisa dilakukan.

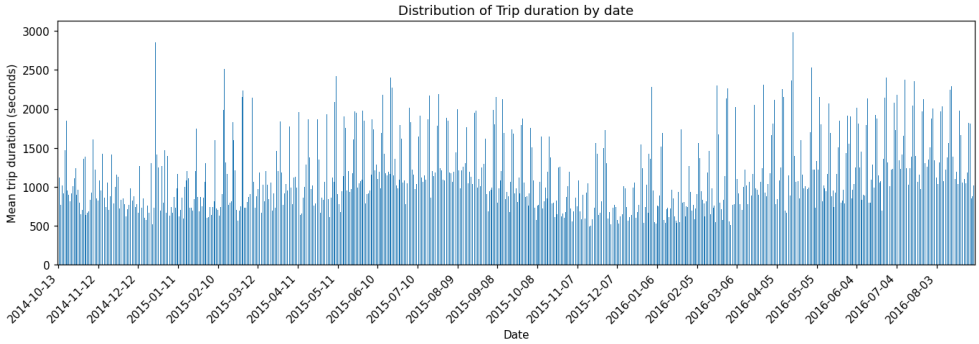
Listing 1-11 dan 1-12: Validasi data demografi Short-Term Pass Holder

Keduanya bernilai **True**: pada seluruh 89.894 trip Short-Term Pass Holder, tahun lahir **dan** gender kosong. Artinya data demografi hanya tersedia untuk Member. Dampaknya langsung: (1) kolom gender dan birthyear hanya mewakili Member (sekitar 62% trip), (2) kesimpulan tentang loyalitas milenial dari Listing 1-8 gugur, dan (3) analisis demografi harus selalu disebut berlaku untuk Member saja.

Listing 1-13: Fitur waktu turunan

Kolom *starttime* yang berupa teks diubah menjadi datetime lalu dipecah menjadi tanggal, tahun, bulan, hari, dan jam. Output menunjukkan setiap trip kini punya komponen waktu yang dapat dikelompokkan, misalnya 13 Oktober 2014 pukul 10:31 menjadi tahun 2014, bulan 10, hari 13, jam 10. Jumlah baris tidak berubah. Langkah ini menjadi dasar semua analisis deret waktu di Listing 1-14 dan bagian 2b.

Listing 1-14: Rata-rata durasi trip per tanggal



Gambar: rata-rata durasi trip (detik) untuk tiap tanggal.

Rata-rata durasi harian berada pada 1.143 detik (sekitar 19 menit) dengan median 1.036 detik. Nilainya bergerak dari **489 detik** (16 Nov 2015) hingga **2.980 detik** (17 Apr 2016). Ada pola yang jelas dan berulang, bukan fluktuasi acak:

Musiman. Rata-rata durasi bulanan tertinggi pada Juli (1.414 detik) dan terendah pada Desember (866) serta Januari (877). Perjalanan lebih panjang di musim panas dan lebih pendek di musim dingin.

Tren antartahun tidak seragam. April, Juli, dan Agustus 2016 lebih panjang daripada 2015 (Juli: 1.526 detik berbanding 1.335 detik), tetapi Januari-Maret 2016 justru lebih pendek.

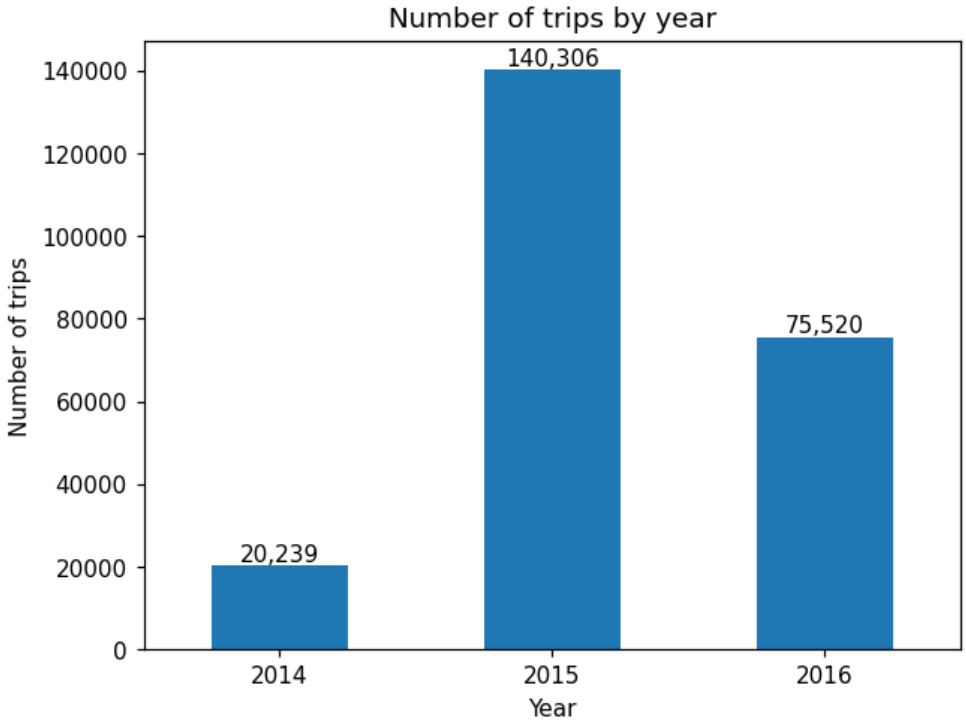
Lonjakan ekstrem. Beberapa hari melonjak jauh di atas pola, seperti 25 Des 2014 (2.857 detik) dan 17 Apr 2016 (2.980 detik). Hari-hari ini kemungkinan didominasi trip rekreasi berdurasi panjang, dan perlu diperiksa sebelum dimasukkan ke model.

Sebagian kenaikan musim panas dapat dijelaskan oleh bauran pengguna: porsi Short-Term Pass Holder yang berdurasi panjang naik dari 21% pada Januari menjadi 50% pada Juli (lihat 2b, bagian E1).

2b. Analisis Output Distribusi Jumlah Trip dan Multivariat

1a. Distribusi jumlah trip per tahun

Tahun	Jumlah trip	Persentase
2014	20.239	8,6%
2015	140.306	59,4%
2016	75.520	32,0%



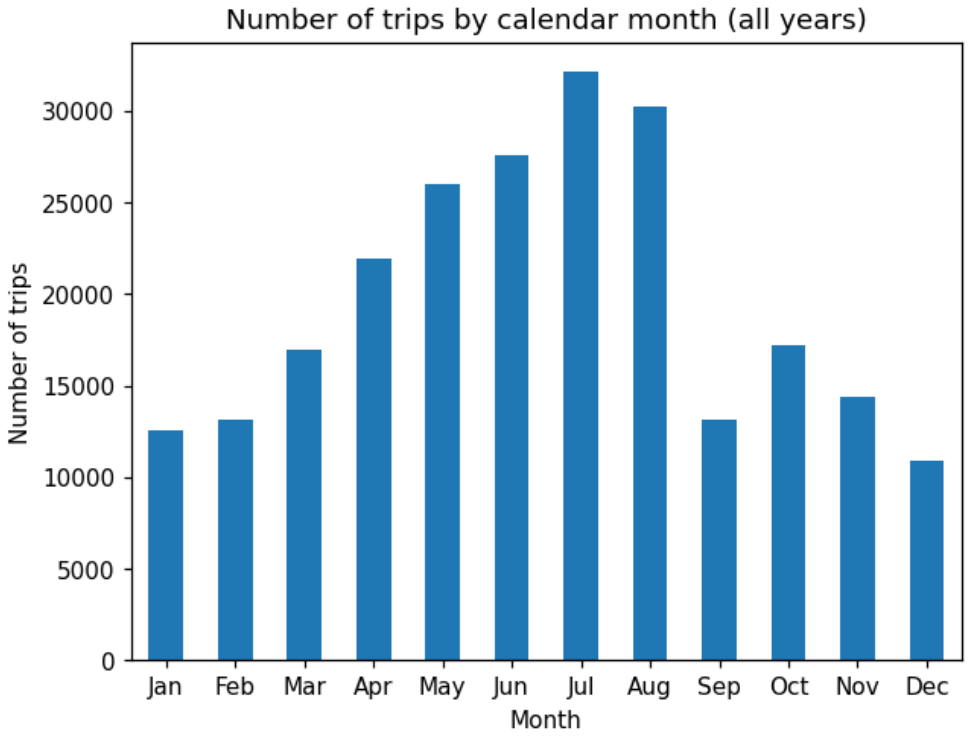
Gambar: jumlah trip per tahun.

2015 adalah tahun terbanyak dengan **140.306 trip (59,4%)**, diikuti 2016 (75.520) dan 2014 (20.239). Perbandingan langsung antartahun menyesatkan karena cakupan tidak sama: 2014 hanya mulai 13 Oktober (sekitar 2,6 bulan) dan 2016 berakhir 31 Agustus (8 bulan); hanya 2015 yang penuh 12 bulan.

Perbandingan yang adil memakai periode sama, Januari-Agustus: 2015 mencatat 104.977 trip dan 2016 75.520 trip, jadi **2016 turun 28,1%** dibanding 2015. Jadi data tidak menunjukkan pertumbuhan, melainkan penurunan penggunaan pada 2016.

1b. Distribusi jumlah trip per bulan (bulan kalender)

Bulan	Jan	Feb	Mar	Apr	Mei	Jun	Jul	Agu	Sep	Okt	Nov	Des
Trip	12.530	13.116	16.953	21.927	26.035	27.547	32.150	30.239	13.134	17.190	14.364	10.880

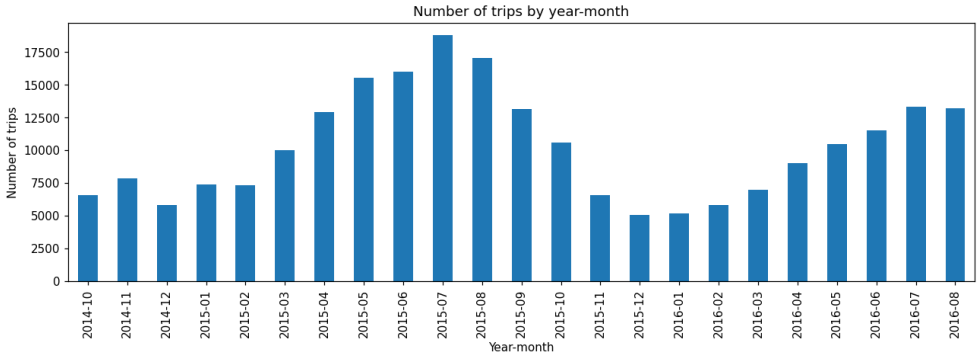


Gambar: jumlah trip per bulan kalender, semua tahun digabung.

Puncaknya **Juli (32,150 trip)** dan terendah **Desember (10,880)**; Juli sekitar 3,0 kali Desember. Jumlah trip naik tajam dari Maret hingga Juli, bertahan tinggi di Agustus, lalu turun menuju musim dingin. Ini pola musiman yang kuat: bersepeda sangat dipengaruhi cuaca dan musim.

Hati-hati membaca September-Desember: bulan-bulan itu hanya diwakili data satu atau dua tahun (September hanya 2015), sedangkan Januari-Agustus punya dua tahun (2015 dan 2016). Penurunan tajam ke September (13.134) sebagian adalah artefak cakupan, bukan penurunan nyata.

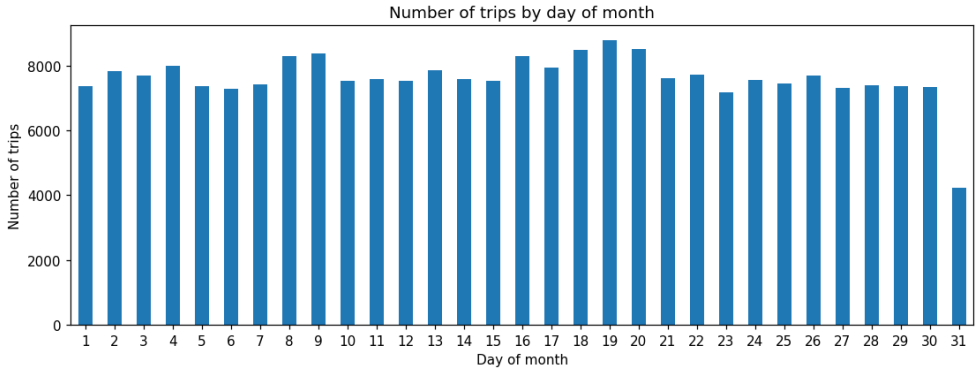
1b (lanjutan). Jumlah trip per tahun-bulan



Gambar: jumlah trip per tahun-bulan (Okt 2014 - Agu 2016).

Tampilan per tahun-bulan menghilangkan masalah cakupan. Puncak tertinggi adalah **Juli 2015 (18.808 trip)**, dasar terendah **Desember 2015 (5.049)**. Siklus musim terlihat jelas dua kali: naik Maret-Juli dan turun Agustus-Desember. Tiap bulan Januari-Agustus 2016 lebih rendah daripada bulan yang sama di 2015, misalnya Juli 2016 13.342 berbanding 18.808. Jadi tren dasarnya turun, dengan pola musiman di atasnya.

1c. Distribusi jumlah trip per hari (tanggal dalam bulan)

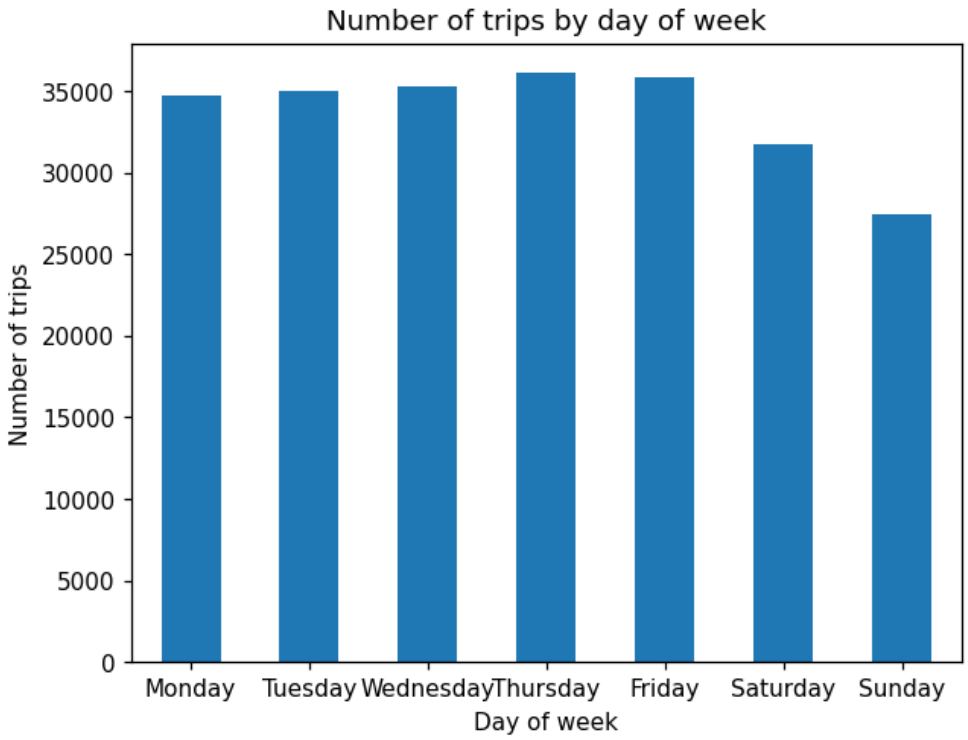


Gambar: jumlah trip per tanggal (1-31).

Untuk tanggal 1-30, jumlah trip berkisar 7.186-8.797, kira-kira rata, sehingga tidak ada pola berarti menurut tanggal dalam bulan. Tanggal 31 hanya 4.239 trip karena hanya 7 dari 12 bulan yang memiliki tanggal 31 (artefak kalender, bukan perilaku pengguna).

1c (lanjutan). Distribusi jumlah trip menurut hari dalam minggu

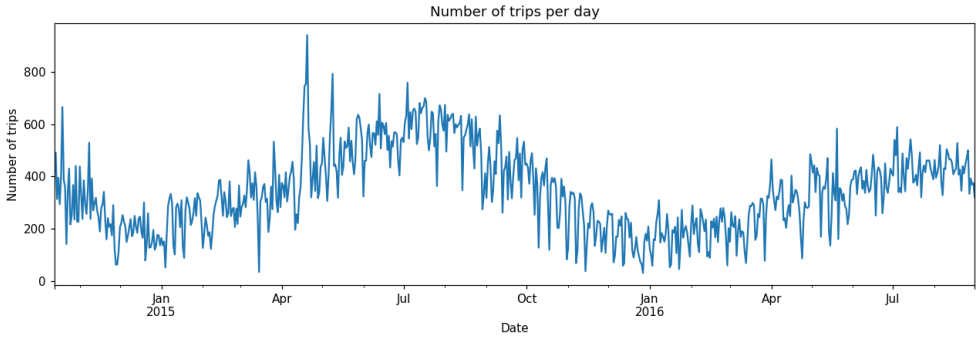
Hari	Jumlah trip	Persentase
Senin	34.704	14,7%
Selasa	35.023	14,8%
Rabu	35.263	14,9%
Kamis	36.122	15,3%
Jumat	35.828	15,2%
Sabtu	31.724	13,4%
Minggu	27.401	11,6%



Gambar: jumlah trip per hari dalam minggu.

Hari kerja stabil di kisaran 34.700-36.100 trip per hari. **Kamis tertinggi (36.122, 15,3%)** dan **Minggu terendah (27.401, 11,6%)**. Rata-rata hari kerja 35.388 trip lebih tinggi 20% daripada akhir pekan (29.562). Ini mengisyaratkan penggunaan utama untuk komuter, yang diperjelas pada bagian multivariat.

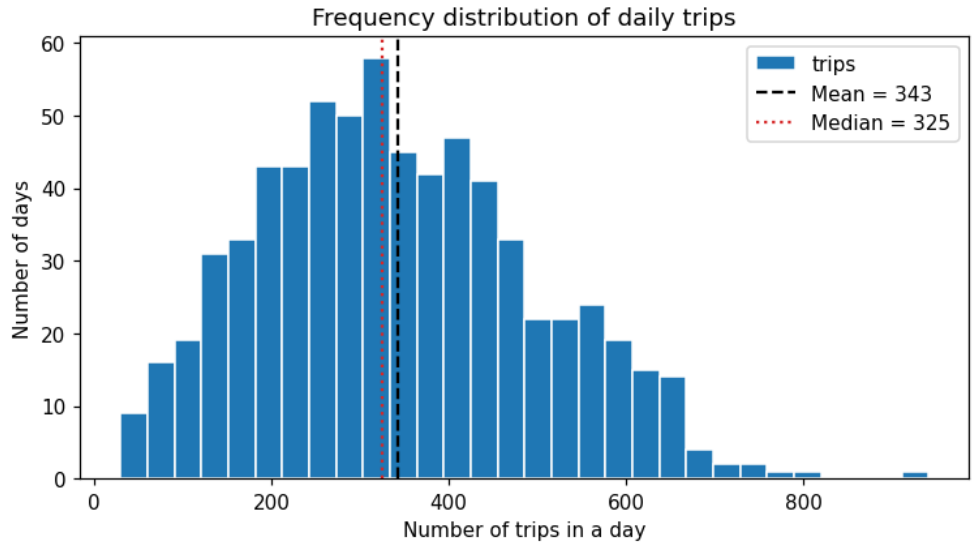
1d. Plot distribusi frekuensi trip harian



Gambar: jumlah trip per tanggal (deret waktu).

Selama 689 hari, rata-rata **342,6 trip per hari** (median 325, simpangan baku 154,9). Minimum 30 trip pada 27 Des 2015; maksimum **941 trip pada 20 Apr 2015**, yang menonjol dari hari-hari lain (hari tertinggi berikutnya 793). Deret waktunya menunjukkan siklus musiman (tinggi di pertengahan tahun, rendah di akhir/awal tahun) dengan fluktuasi harian yang besar di sekelilingnya.

1d (lanjutan). Histogram frekuensi harian



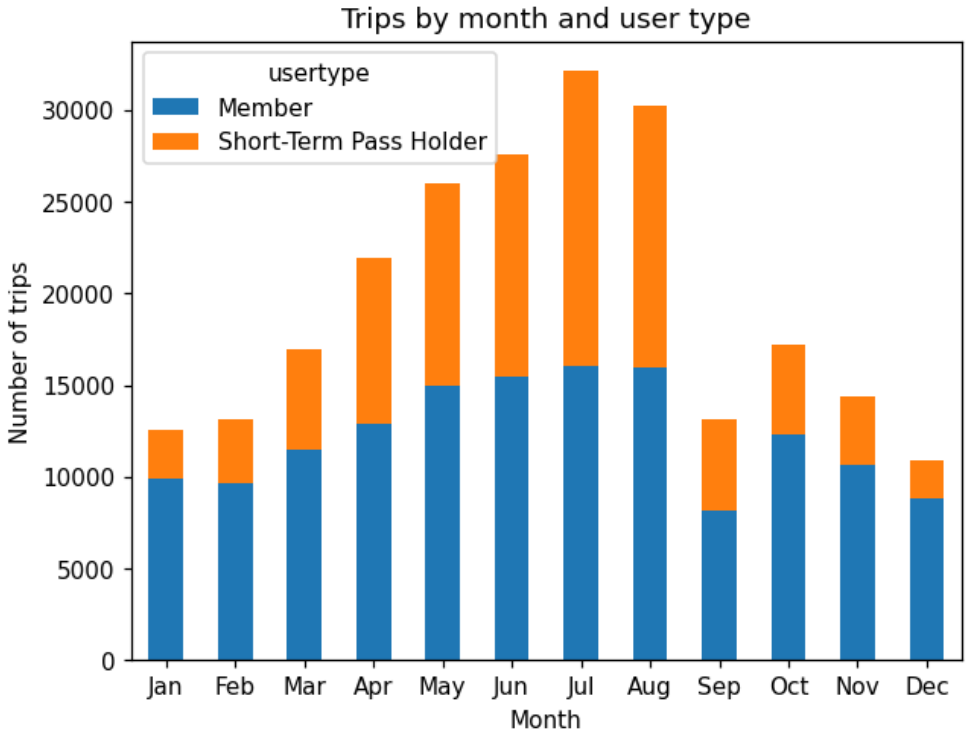
Gambar: histogram jumlah trip per hari (jumlah hari di tiap rentang).

Distribusinya **unimodal dan sedikit condong ke kanan** (skewness 0,36; rata-rata 343 sedikit di atas median 325). Hampir separuh hari berada pada 200-400 trip (321 dari 689 hari, 47%). Hari sepi (100 trip atau kurang) hanya 31 hari, sedangkan hari ramai di atas 600 trip 44 hari. Sebaran lebar ini berasal dari musim dan hari dalam minggu.

Analisis multivariat

Bagian ini melihat dua variabel atau lebih bersamaan untuk menjelaskan pola yang tidak terlihat pada analisis satu variabel.

E1. Bulan dan tipe pengguna

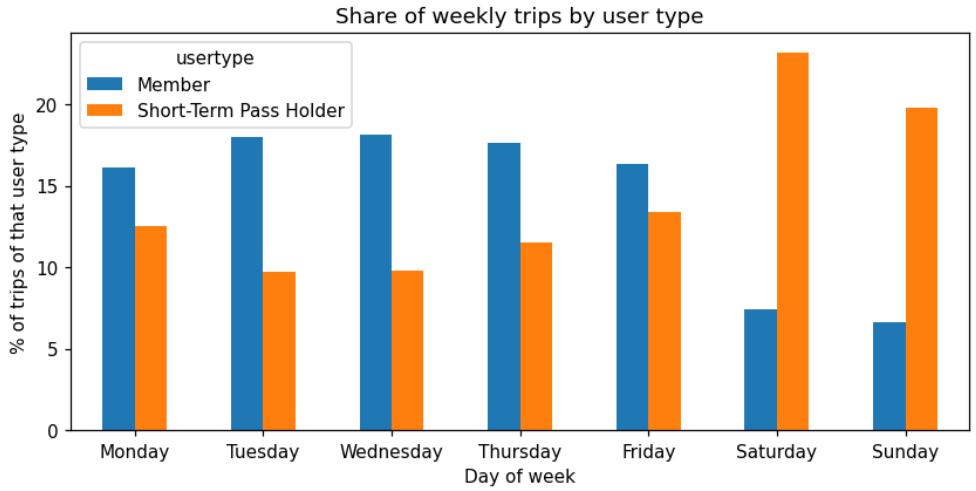


Gambar: jumlah trip per bulan, ditumpuk menurut tipe pengguna.

Member relatif stabil sepanjang tahun: dari 9,902 trip (Januari) menjadi 16,057 (Juli), naik 1,6 kali, Short-Term Pass Holder sangat musiman: dari 2,628 menjadi 16,093, naik **6,1 kali**, Pada Juli Short-Term (16.093) bahkan setara Member (16.057). Jadi sebagian besar lonjakan musim panas berasal dari pemakai jangka pendek, sedangkan basis Member memberi permintaan dasar yang stabil.

E2. Hari dalam minggu dan tipe pengguna

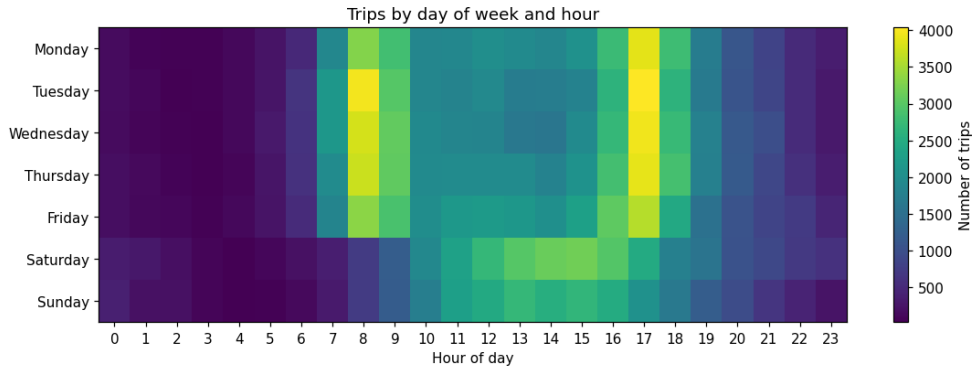
Hari	Member (%)	Short-Term (%)
Senin	16,1	12,5
Selasa	18,0	9,7
Rabu	18,1	9,8
Kamis	17,6	11,5
Jumat	16,3	13,4
Sabtu	7,4	23,2
Minggu	6,6	19,8



Gambar: porsi trip mingguan tiap tipe pengguna menurut hari.

Member melakukan **86,0%** trip pada hari kerja dan hanya 14,0% pada akhir pekan, Short-Term kebalikannya: **43,1%** trip terjadi di Sabtu-Minggu, Sabtu adalah hari tersibuk Short-Term (23,2%), sedangkan Member paling aktif Selasa-Rabu. Ini mendukung gambaran Member sebagai komuter dan Short-Term sebagai pemakai rekreasi akhir pekan. Kenaikan jumlah trip pada hari kerja yang terlihat di 1c berasal dari Member.

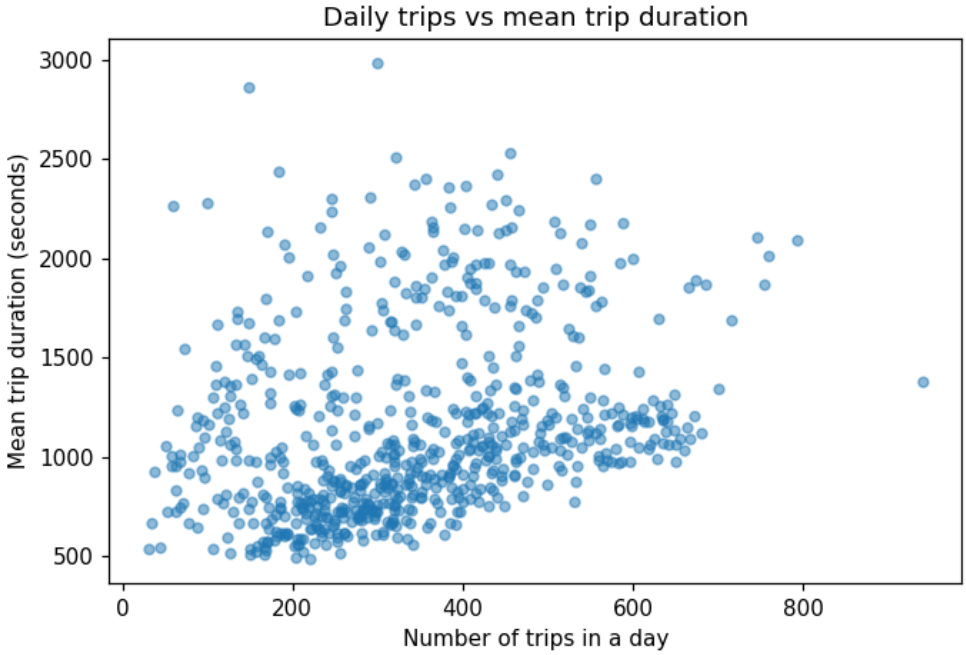
E3. Hari dan jam (heatmap)



Gambar: jumlah trip menurut hari dalam minggu dan jam mulai.

Hari kerja berpola **dua puncak**: pagi pukul 08:00 (18.094 trip) dan sore pukul 17:00 (19.337 trip), tipikal jam berangkat dan pulang kerja. Jam 07-09 dan 16-18 memuat 50,6% seluruh trip hari kerja. Akhir pekan berpola **satu puncak siang**, tertinggi pukul 15:00 (5.826 trip) dan merata pukul 13-15. Perbedaan bentuk ini sejalan dengan temuan E2: hari kerja didominasi komuter, akhir pekan rekreasi.

E4. Jumlah trip harian dan rata-rata durasi harian



Gambar: diagram pencar jumlah trip harian terhadap rata-rata durasi harian.

Korelasi Pearson **0,28** dan Spearman **0,37** menunjukkan hubungan positif lemah sampai sedang: hari yang lebih ramai cenderung berdurasi rata-rata lebih panjang. Spearman yang lebih besar daripada Pearson berarti hubungannya lebih konsisten secara peringkat (hari ramai umumnya lebih panjang) daripada berbentuk garis lurus. Hubungan ini bukan sebab-akibat: musim panas menambah jumlah trip sekaligus porsi Short-Term yang berdurasi panjang (E1), sehingga keduanya naik bersama karena faktor ketiga.

E5. Tahun dan tipe pengguna

Tahun	Member	Short-Term	Porsi Member
2014	13.879	6.360	68,6%
2015	88.262	52.044	62,9%
2016	44.030	31.490	58,3%

Porsi Member turun dari 68,6% (2014) ke 62,9% (2015) dan 58,3% (2016). Penurunan ini sebagian besar adalah efek cakupan bulan: 2014 hanya memuat Oktober-Desember (musim dingin, didominasi Member) dan 2016 tidak memuat September-Desember. Pada periode pembanding Januari-Agustus, porsi Member nyaris sama: **59,2% (2015) berbanding 58,3% (2016)**. Penurunan jumlah trip 2016 terjadi pada kedua tipe: Member turun 29% dan Short-Term turun 26%.

Kesimpulan

Penggunaan sepeda Seattle sangat dipengaruhi musim dan jenis pengguna. Member (62% trip) adalah komuter dengan pola hari kerja dan jam sibuk pagi-sore yang stabil, sedangkan Short-Term Pass Holder (38%) adalah pemakai rekreasi yang melonjak di musim panas dan akhir pekan, dengan durasi trip jauh lebih panjang. Data demografi (gender, tahun lahir) hanya tersedia untuk Member, sehingga temuan demografi tidak berlaku bagi seluruh pengguna. Pada periode pembanding yang sama, jumlah trip 2016 lebih rendah sekitar 28% daripada 2015.